


## Background & Obejctives

복부 내 air fluid level은 다양한 이유로 변화하게 되는데, 내시경, 기타 시술 등의 외적인 요소 뿐만 아니라, 환자의 장 내 폐쇄 등에 의해서 영향을 받게 된다. 하지만, 이를 정량화하고 시각화해주는 기술이 없기 때문에 환자의 air fluid level에 대한 해석은 이미지를 해석하는 사람에 의해 inter-observer variability가 존재할 수 밖에 없게 된다. 따라서 복부 내 air fluid level을 정량화 하는 방법론을 제안하였고, 구현된 시스템을 제안한다.

(위, 소장, 대장의 air를 복부 내 air로 통칭함)

2. 복부 내 Air-Fluid에 해당되는 부분을 segmentation하는 모델을 제작함.

Biomedical 분야에서 Segmentation 알고리즘 기반의 딥러닝 AI 모델을 사용한 사례는 많이 있었음. cell segmentation(아래의 이미지 참고)이나 lung segmentation for Chest X-ray 등. 그러나 복부 내 air를 segmentation하는 연구에 대한 사전 연구를 찾아볼 수 없으며, 이 연구 및 시스템의 개발은 장 내 air fluid level을 측정하는 첫 연구로 보여짐.



출처: U-Net : Convolutinal Network for Biomedical Image Segmentation, MICCAI 2015

3. Air fluid가 있음에도 불구하고, 공기의 양에 따라 X-ray 상의 이미지 패턴 및 색이 달라짐, 이 연구에서는 이를 활용하여 air-fluid 위치 뿐 만 아니라 공기의 양을 정량화 하는 알고리즘을 만듦.

## Method background

주관적으로 판단하던 복부 air fluid level의 양을, Segmentation 알고리즘 기반의 딥러닝 AI 모델 개발을 통해 객관적으로 정량화 할 수 있는 알고리즘을 만드는데 목표. 이 연구에서는 딥러닝 알고리즘으로, U-Net을 사용한 Semantic Segmentation을 구현하였음. 다만 U-Net 뿐 만 아니라, FCN, SegNet, PSPNet 등의 알고리즘으로 대체할 수 있음.

또한, 복부 air fluid level에 해당하는 x-ray 상의 색상을 활용해 공기층의 깊이를 알 수 있으며, 이

를 활용하여 복부 내 air의 양을 정량화하고, 시각화 하는 메소드를 구현하였음


이러한 시각화를 통해 공기를 삽입하여 시술하는 장 내 종양이나 용종 절제술의 시술 전후 복부 내 air의 양을 비교하여 시술 전후의 차이를 알 수 있음.

따라서 복부 air에 따른 복부 내 장기의 팽창에 따라 환자의 상태를 진단하는 보조적인 수단으로 사용할 수 있을 것이라 생각되어 진행하게 됨.

## Method & Result

### 1. 데이터 수집 및 마스크 데이터 제작

#### 가. 수집데이터



출처: 아주대학교 소화기내과

Figure 1. 복부(Abdominal) X-Ray

Figure 1과 같이 데이터는 3024x2520x3 크기의 장 내 종양이나 용종 절제술 전, 후 paired 된 환자의 복부(Abdominal) X-Ray 이미지 20장과 다양한 복부 air음영을 가진 X-Ray이미지 16장으로 총 36장을 제공받음

#### 나. 마스크 Label, 데이터 제작




Figure 2. Labelme를 활용한 annotation 과정 화면 캡처




Figure 3. X-Ray이미지와 Mask 이미지 데이터셋 생성 결과 예시

U-Net을 사용한 복부의 air를 Segmentation Tool을 제작하기에 앞서 X-Ray이미지에서 복부의 air mask를 그리는 수작업을 필요로 함. 그래서 annotation Tool인 Labelme를 사용하여 polygon을 생성하여 36장의 air mask이미지 제작을 수행하였고, 데이터 세트를 해당 레이블(X-Ray이미지)과 air와 background가 구분된(0 or 1) 마스크로 구성함. X-ray 이미지 내 폐의 경우에는 공기가 실제로 존재함에도 불구하고, 공기가 없는 것으로 Label을 제작함.

#### 다. Elastic Deformation 기법을 활용한 Data Augmentation 수행




Figure 4. (좌) 원본 X-Ray이미지 , (우) Elastic Deformation을 통해 변형된 Augmented X-Ray이미지 결과

Figure 4의 우측의 이미지와 같이 Elastic Deformation을 통한 변형을 주는 것은 Biomedical분야에서 조직의 변형을 현실적으로 시뮬레이션 할 수 있다는 점에서 많이 사용되는 Augmentation기법이다. 일반적으로 사용되는 image augmentation 기법들은 현실과 매우 동떨어진 방식이므로, 이 연구에서는 Elastic Deformation만을 통해 augmentation을 수행하였다.

추가적인 데이터를 얻기 위해서 annotation Tool을 통한 labeling 작업을 통해 데이터를 생성하는 방법도 있으나 많은 수작업을 필요로 한다는 단점이 있음. 그러므로 Elastic Deformation을 통해 레이블(X-Ray이미지)와 마스크 이미지에 동일한 방식으로 변형을 주어 데이터 셋을 648장으로 증폭시켰다.

## 2. U-Net을 활용한 Semantic Segmentation Tool 생성




Figure 5. **U-Net : Convolutinal Network for Biomedical Image Segmentation, MICCAI 2015**

### 가. Semantic segmentation model: U-Net

U-Net은 biomedical 분야에서 Image Segmentation을 목적으로 제안된 End-to-End방식의 Fully-Convolutional Network 기반 모델로 네트워크의 구성이 'U'형태로 되어있어 U-Net이라는 이름이 붙여짐.

적은 양의 학습데이터로도 여러 Biomedical Image Segmentation에 우수한 성능을 보이며, patch 탐색 방식으로 이전 방법들(DCNN, sliding window를 사용한 IDSIA network)에 비해 빠른 속도로 훈련이 가능하여 선택함.

## 나. 모델 정의 및 적용

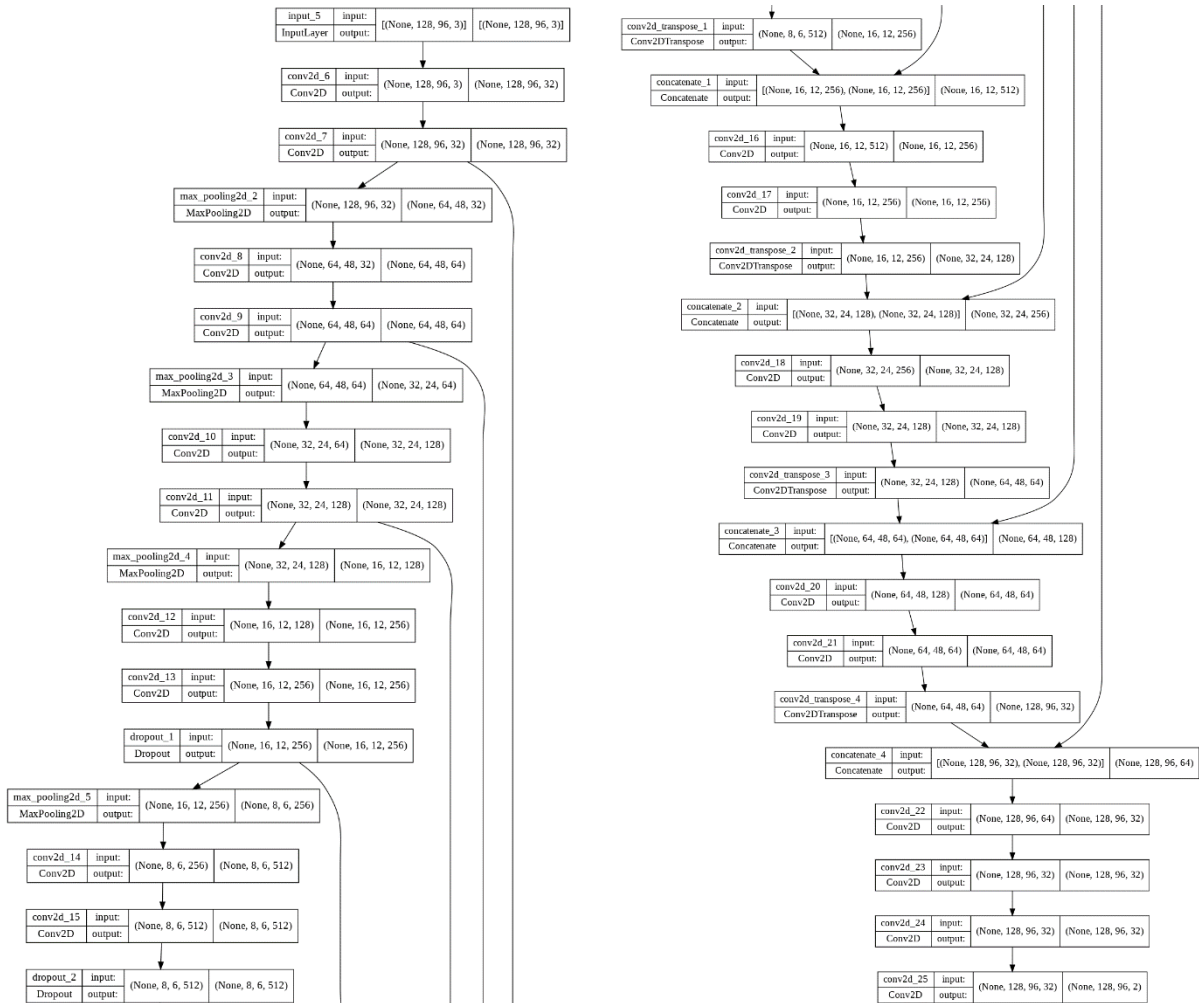


Figure 6. U-Net 모델의 Encoder (좌), U-Net 모델의 Decoder (우)

Figure 6과 같이 모델을 구성하였음. 활성화함수(activation function)는 ReLu, 손실 함수(loss function)는 Sparse Categorical Crossentropy를 사용함. 옵티마이저(optimizer)는 Adam을 사용하며, 각 네트워크 가중치에 대해 학습률이 유지되며 학습이 전개될 때 별도로 작동함.




Figure 7. (좌)U-Net 모델의 Accuracy, (우) U-Net 모델의 Loss



Figure 7의 그래프와 같이 모델 훈련결과 Accuracy는 0.98, Loss는 0.031임.

### 3. 분석

가. Train & Test dataset 출력 이미지 예시

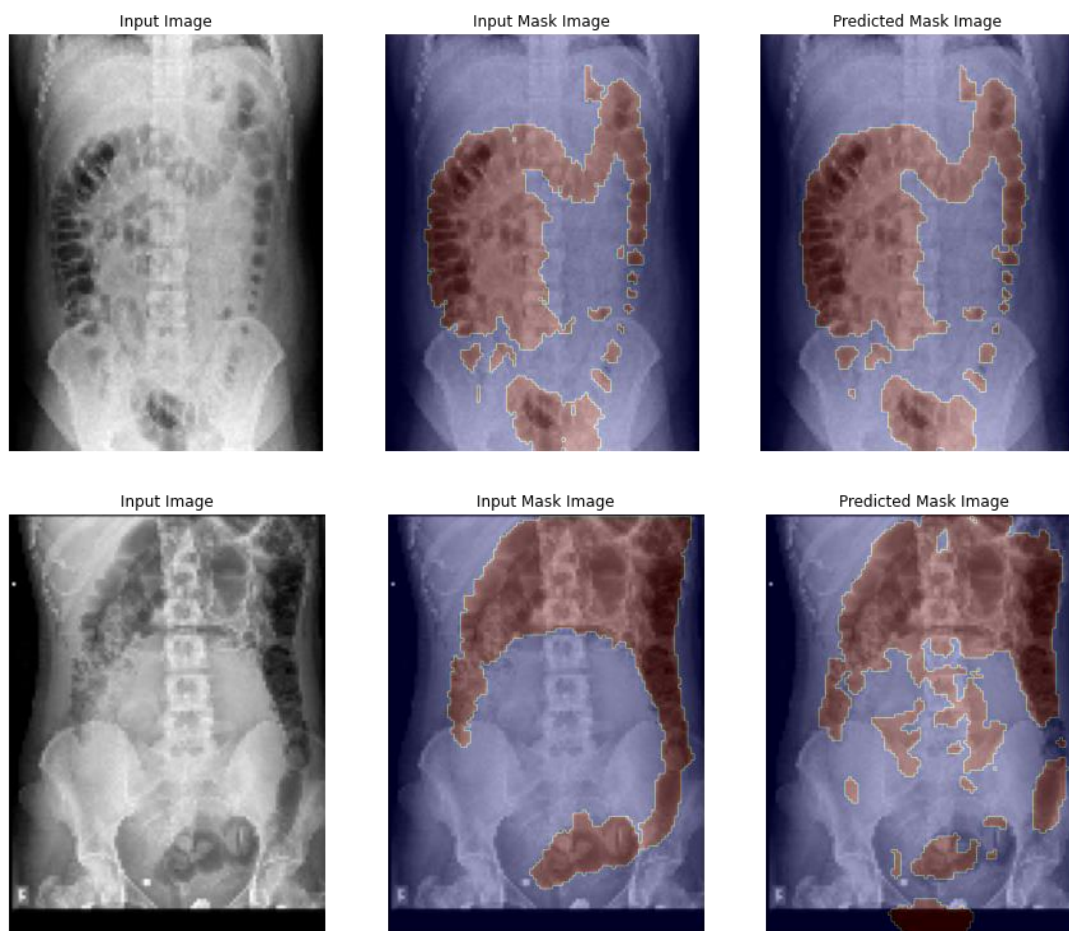



Figure 8. Train dataset으로부터 출력한 값 예시 2가지 (위, 아래)

Figure 8는 Train과 Test dataset으로부터 출력한 데이터로 좌측부터 원본 X-Ray이미지, Input Mask 합성 이미지, Predicted Mask의 합성 이미지임.

나. 인식 모델 평가지표 : IoU Score

모델의 성능을 평가할 때 Input Mask와 Predicted Mask가 사이의 IoU를 사용함.

실제 마스크와 예측 마스크가 얼마나 겹치는 지를 따져 얼마나 잘 예측했는지 성능을 평가하는 지표임.



$$IoU = \frac{Input\ Mask \cap Predicted\ Mask}{Input\ Mask \cup Predicted\ Mask}$$

(<https://www.pyimagesearch.com/2016/11/07/intersection-over-union-iou-for-object-detection/>)

Train dataset의 Average IOU Score는 0.89, Test dataset의 Average IoU Score는 0.68이 나옴.

이는 예측값이 실제 복부의 air를 잘 표현하고 있다는 지표가 됨

다. Predicted Mask의 공기층 시각화




Figure 9. 2가지 case에 대한 복부 X-Ray 이미지의 Air-fluid에 해당되는 영역 (좌) 및 공기의 밀도에 따른 공기층 시각화 (우). 좌측 이미지는 Validation data, 우측 이미지는 Test data에 해당함.

Figure 9 의 좌측 이미지와 같이 (X-Ray 이미지 \* Predicted Mask)를 하여 Predicted Mask가 1인 부위(air인 부위)만 뽑아서 추출함. Predicted Mask가 1인 부위만 추출한 이미지를 이용하여 공기층이 깊은 곳은 붉게, 공기층이 얇을수록 푸르게 표시되도록 이미지 라이브러리인 opencv를 사용하여 Figure 10, 11의 우측 이미지와 같이 colormap으로 시각화 함.

라. Predicted Mask 공기량 정량화






Figure (위)Train Predicted Mask의 공기량: 44.68%, Test Predicted Mask의 공기량: 56.4%

Figure 10. (순서대로)1-(X-Ray이미지\*Predicted Mask), np.ones(128, 96, 1)-Predicted Mask, air\_volume

이미지상 어두울수록 공기층이 깊으나 0과 1 사이의 값에서 어두울수록 0에 가까운 값을 가지므로,  $1 - (\text{X-Ray 이미지} * \text{Predicted Mask})$ 하여 공기의 깊이에 따른 array값을 구할 수 있음. 그러나 background가 값을 1을 가지게 되므로,  $\text{np.ones}((128,96,1)) - \text{Predicted Mask}$ 를 빼고 Figure 11의 세번째 이미지와 같은 air\_volume을 구할 수 있음.

따라서,  $\text{air} = \left\{ \frac{\text{np.sum}(\text{air volume})}{128*96} \right\} * 100$  을 통해 공기량을 정량화 할 수 있음.

#### 4. 결론

- 1) U-Net을 통해 학습한 복부 X-Ray의 air mask를 통해 복부의 air를 예측하는 mask를 그릴 수 있으며, 더 나아가 air mask에서 공기층의 깊이를 밝기를 통해 표현하여 공기층이 어떤 장기에 깊게 분포하는지 알 수 있음.
- 2) air segmentation mask의 면적이 넓은 것으로 air의 양을 판단하는 것이 아닌, 공기층이 깊을수록 더 높은 수치를 주어 좀 더 입체적으로 air의 양을 정량화 할 수 있음.
- 3) 이 연구에서는 복부 의료이미지를 활용하여, polygon을 통해 Mask를 생성하는 방법, 그리고 Segmentation 알고리즘을 구현하고 학습하는 방법, 도출된 segmentation 결과로부터 공기층을 시각화 하는 방법, 공기층을 정량화하는 파이프라인을 구현하였음.